



Escola Politécnica

NÚCLEO DE ELETIVAS INTERESCOLAS DA ESCOLA POLITÉCNICA

Curso: Ciências da Computação

Disciplina: Processamento de Imagens

Professor: Felipe Viel

Projeto M1 – Operações Pontuais e Filtragem Espacial

Acadêmicos:

Ismael Antonio da Silva Junior

Lucas Lopes Baroni

Itajaí, setembro, 2026

Sumário

1. INTRODUÇÃO.....	4
1.1 Enunciado do projeto.....	4
1.2 Contexto da aplicação.....	5
2. DESENVOLVIMENTO.....	5
2.1 Seleção das imagens.....	7
2.2 Caracterização inicial.....	7
2.3 Inserção de ruído: gaussiano.....	8
2.4 Operação pontual: equalização de histograma.....	9
2.5 Suavização: filtro gaussiano.....	10
2.6 Aguçamento: high-boost.....	10
2.7 Configurações do pipeline.....	11
2.8 Métricas escolhidas.....	12
3. IMPLEMENTAÇÃO.....	12
3.1 Conversão para tons de cinza e histograma.....	13
3.2 Equalização de histograma.....	13
3.3 Convolução e tratamento de bordas.....	14
3.4 Máscaras de suavização e filtro da mediana.....	16
3.5 Aguçamento: laplaciano e high-boost.....	18
3.6 Avaliação por métricas.....	19
3.7 Montagem das configurações do pipeline.....	19
4. RESULTADOS OBTIDOS.....	20
4.1 Imagens originais.....	20
4.2 Conversão para tons de cinza e inserção de ruído.....	22
4.3 Histogramas das imagens degradadas.....	24
4.4 Operação pontual: equalização de histograma e correção gama.....	26
4.5 Suavização.....	30

4.6	Aguçamento.....	32
4.7	Configurações completas do pipeline.....	35
	Configuração 1 – ruído → equalização → gaussiano → high-boost.....	35
	Configuração 2 – ruído → gaussiano → equalização → high-boost.....	38
	Configuração 3 – equalização → ruído → gaussiano → high-boost.....	39
5.	ANÁLISE E DISCUSSÃO.....	40
5.1	Comparação entre as configurações.....	40
5.2	Melhor configuração por imagem.....	42
5.3	Comportamentos inadequados e limitações.....	43
	Filtro da mediana sobre ruído gaussiano.....	43
	Equalização de histograma aplicada sobre imagem ruidosa.....	43
	Realce de artefatos junto com as estruturas de interesse.....	43
	Laplaciano e a escolha do fator c.....	44
	Queda do PSNR na etapa de aguçamento.....	44
	Limitações do experimento.....	44
5.4	Conclusão.....	45
6.	REFERÊNCIAS BIBLIOGRÁFICAS.....	46

1. INTRODUÇÃO

O processamento digital de imagens ocupa um lugar importante em aplicações voltadas à saúde, principalmente quando as imagens precisam ser preparadas antes de uma análise humana ou de uma etapa automática de classificação. Variações de iluminação, diferenças de contraste, ruído de captura e perda de definição das estruturas afetam tanto a leitura clínica quanto o desempenho de métodos computacionais aplicados depois.

O conjunto International Skin Imaging Collaboration (ISIC) reúne imagens dermatoscópicas de lesões de pele, incluindo melanomas, e foi a base utilizada neste trabalho. Foram selecionadas três imagens de melanoma e sobre elas foi construído um pipeline de melhoria composto por uma operação pontual de transformação de intensidade e etapas de filtragem espacial e outra de aguçamento.

Todas as operações pontuais e de filtragem foram implementadas pelo grupo, sem uso de funções prontas de biblioteca que executem integralmente a operação solicitada. O código foi desenvolvido em Python, no Google Colab, e está disponível junto com este relatório.

1.1 Enunciado do projeto

O projeto pede o desenvolvimento de um pipeline de melhoria de imagens médicas utilizando operações pontuais e técnicas de filtragem espacial sobre imagens do conjunto ISIC. O objetivo não é apenas aplicar filtros, mas investigar como diferentes transformações alteram as características visuais da imagem e determinar, por meio de métricas quantitativas, qual combinação oferece o melhor compromisso entre melhoria do contraste, redução de ruído e preservação ou realce de detalhes.

O fluxo solicitado é o seguinte:

- **Seleção das imagens:** escolher três melanomas de uma mesma região anatômica do conjunto ISIC e justificar a seleção.
- **Caracterização inicial:** apresentar as imagens originais e identificar seus principais problemas de qualidade.
- **Inserção de ruído:** adicionar ruído controlado às imagens e registrar os parâmetros utilizados.
- **Operação pontual:** aplicar uma técnica de transformação de intensidade escolhida pelo grupo.

- **Suavização:** reduzir o ruído utilizando uma técnica de filtragem espacial.
- **Aguçamento:** realçar detalhes ou estruturas utilizando uma técnica espacial adequada.
- **Segunda configuração:** modificar uma técnica, parâmetro ou ordem do pipeline e repetir o processamento.
- **Análise por métricas:** selecionar duas métricas apresentadas em aula e usá-las para comparar as imagens original, degradada e processadas, justificando a escolha.
- **Discussão:** identificar qual configuração apresentou o melhor resultado para cada imagem e discutir situações em que alguma técnica apresentou comportamento inadequado.

O enunciado permite alterar a ordem das etapas desde que haja justificativa técnica, e exige que as funções de processamento sejam implementadas pelos alunos.

1.2 Contexto da aplicação

A premissa adotada é que as imagens serão usadas como entrada de uma etapa posterior de análise computacional, por exemplo um classificador de lesões. Antes disso, é preciso avaliar se o pré-processamento realmente melhora a qualidade da imagem ou se acaba introduzindo artefatos que atrapalham as estruturas relevantes.

No caso específico do melanoma, os critérios visuais mais usados no rastreamento clínico dependem justamente de borda, variação de cor, assimetria e textura interna da lesão. São exatamente essas características que um filtro de suavização mal dimensionado pode apagar e que um aguçamento excessivo pode distorcer. Por isso, o trabalho não se limita a aplicar às operações: cada etapa foi testada com mais de uma técnica e é avaliada por métricas objetivas antes de ser fixada no pipeline.

Os principais desafios tratados são a variação de contraste entre lesão e pele, a presença de ruído de captura, a perda de detalhes causada pela suavização, o realce excessivo produzido pelo aguçamento e o fato de que uma técnica boa para uma imagem pode não ser a melhor para outra.

2. DESENVOLVIMENTO

Esta seção descreve as decisões técnicas tomadas em cada etapa do pipeline e as justificativas por trás delas. Os resultados numéricos que embasam essas decisões estão reunidos na Seção 4.

2.1 Seleção das imagens

Antes de escolher as imagens, é fundamental estabelecer o objetivo do pipeline a ser desenvolvido. Isso porque ele orientará os critérios que devem ser utilizados para selecionar as capturas adequadas para testes.

Por isso, visando consolidar um pipeline genérico para lidar com o tratamento de diferentes melanomas, nosso grupo escolheu o seguinte objetivo: modelar um conjunto de etapas sequenciais de processamento de imagens que viabilizem a correção e realce de formas e detalhes de melanomas com distintos contrastes e qualidades de captura.

Com esse objetivo em mãos, para avaliar se o trabalho desenvolvido atende às necessidades estabelecidas por ele, precisamos selecionar imagens que fazem parte do escopo que ele promete melhorar. Por isso, os critérios a serem utilizados para nortear a avaliação do desempenho do pipeline baseia-se na escolha de imagens com:

- **Variação do contraste** do melanoma em relação à pele;
- **Presença ou ausência de artefatos visuais** que podem prejudicar a análise da imagem.

Nesse contexto, foram escolhidas as seguintes imagens da base de dados ISIC: *ISIC_0010925.jpg*, *ISIC_0011094.jpg* e *ISIC_0001119.jpg*.

A apresentação das imagens e sua devida caracterização serão desenvolvidas no próximo tópico. Ademais, será possível compreender melhor porque as imagens possuem características desejáveis para os critérios que estabelecemos.

2.2 Caracterização inicial

- **Imagem 1 - ISIC_0010925.jpg**: Ela apresenta um melanoma presente em uma região bem delimitada, com cores e bordas que se destacam da tonalidade da pele (bom contraste). O principal problema de qualidade presente nela são as linhas horizontais presente na parte direita da figura, referente a lente utilizada na captura da fotografia. Apesar disso, como essas linhas estão em uma região que não possui partes do melanoma, ele tende a não

prejudicar processamentos futuros e análises. Ela foi escolhida para os testes principalmente pelo fato de apresentar um melanoma bem definido e com bom contraste.

- **Imagem 2 - ISIC_0011094.jpg:** Ela apresenta um melanoma bem disperso, com cores e bordas fracas em relação a tonalidade da pele (baixo contraste). Como o melanoma é mais "discreto" quando comparado com os demais, um dos problemas de qualidade da imagem é justamente a delimitação clara das características da lesão. Ademais, existe um pequeno desfoque das informações mais próximas da borda. Ela foi escolhida para os testes principalmente pelo fato de apresentar um melanoma pouco definido, disperso e com baixo contraste.
- **Imagem 3 - ISIC_0001119.jpg:** Ela apresenta um melanoma presente em uma região bem delimitada da pele, com cores e bordas intensas em relação à tonalidade da pele (bom contraste). Apesar disso, a imagem possui inúmeros problemas de qualidade que podem atrapalhar a análise clínica do caso, dentre eles temos: excesso de fios de cabelo na região, data e horário da captura no canto inferior direito, linhas diagonais no canto inferior esquerdo da imagem, referente a lente utilizada na captura da fotografia. Ela foi escolhida para os testes devido aos diversos artefatos presentes.

Com esse conjunto de imagens, torna-se possível consolidar testes robustos levando em consideração variações significativas na intensidade, contraste, distribuição espacial e artefatos ruidosos.

2.3 Inserção de ruído: gaussiano

Todo o processamento foi feito em tons de cinza. A conversão usa a combinação ponderada dos canais BGR lidos pelo OpenCV, com os pesos 0,114 para o azul, 0,587 para o verde e 0,299 para o vermelho, que correspondem à percepção de luminância do sistema visual humano.

O ruído escolhido foi o **gaussiano aditivo**. Ele representa de forma simplificada as perturbações aleatórias associadas aos componentes eletrônicos e térmicos do sistema de captura, que é o caso mais comum no cenário proposto. A captura por sensores costuma combinar ruído de fótons, normalmente modelado por Poisson, e ruído eletrônico de leitura e térmico, frequentemente aproximado por uma gaussiana aditiva. Esse é o modelo Poisson-Gaussiano proposto por Foi et al. (2008) para sensores digitais, e a parcela gaussiana é a que dominamos com as ferramentas vistas em aula.

O ruído foi inserido com a função *random_noise* da biblioteca *scikit-image*, usando *mode="gaussian"* e *var=0.003*. Esse valor corresponde a um desvio padrão de aproximadamente 0,0548 na escala normalizada [0, 1], ou cerca de 14 níveis de cinza na escala de 0 a 255. É uma perturbação visualmente perceptível, mas que ainda preserva as estruturas gerais da lesão, o que permite avaliar de forma controlada a capacidade dos filtros de suavização e de realce. O nível foi classificado como moderado e mantido igual para as três imagens e para as três configurações, de modo que a comparação entre elas fosse justa.

Vale registrar uma decisão de escopo: o enunciado proíbe o uso de funções prontas para as **operações pontuais e de filtragem**, que são o objeto do trabalho, e todas elas foram implementadas do zero. A geração do ruído e o cálculo das métricas não fazem parte desse conjunto e por isso foram delegados ao *scikit-image*, garantindo que a degradação e a avaliação seguissem uma referência padronizada e reproduzível. Ademais, o professor utilizou essa função em atividades propostas em sala.

2.4 Operação pontual: equalização de histograma

Foram implementadas e testadas duas técnicas de transformação de intensidade, a **equalização de histograma** e a **correção gama**.

A análise dos histogramas das imagens degradadas mostrou que nenhuma das três ocupa de forma uniforme toda a faixa de níveis de cinza. Em *ISIC_0011094.jpg* o histograma está fortemente concentrado em tons claros, o que explica o baixo contraste entre lesão e pele. Em *ISIC_0001119.jpg* a concentração é em tons médios, com uma cauda em direção às baixas intensidades associada tanto à lesão quanto aos pelos. Em *ISIC_0010925.jpg* a distribuição é mais ampla, com maior peso nas intensidades médias e claras.

A correção gama foi aplicada com $\gamma = 1,3$, valor que produz um escurecimento moderado. O mesmo parâmetro foi usado nas três imagens para manter a comparação consistente e evitar um ajuste individual que favorecesse alguma delas. O resultado foi uma alteração de brilho global com ganho limitado de contraste: os histogramas continuaram concentrados em faixas intermediárias.

A equalização de histograma redistribuiu os níveis de cinza por uma faixa mais ampla de intensidades, o que aparece claramente nos histogramas resultantes e se traduz em maior separação entre regiões escuras, médias e claras. Um ponto adicional a favor dela é que a transformação é

derivada da distribuição da própria imagem, enquanto a correção gama depende da escolha de um único valor de gama que dificilmente serve bem para as três imagens ao mesmo tempo.

Por esses motivos a **equalização de histograma** foi adotada como operação pontual do pipeline.

2.5 Suavização: filtro gaussiano

Foram implementados três filtros de suavização: **média**, **gaussiano** e **mediana**. Todos foram aplicados com janela 3x3, considerando o pixel central e seus oito vizinhos. Esse tamanho foi escolhido por realizar uma suavização moderada, reduzindo o risco de eliminar junto com o ruído pequenas estruturas relevantes da lesão. Para o filtro gaussiano foi usado $\sigma = 1,0$, que concentra mais peso nos pixels próximos ao centro da máscara e suaviza de forma mais gradual que a média simples.

As métricas mostraram um empate prático entre média e gaussiano: o filtro da média foi numericamente melhor em *ISIC_0010925.jpg* e *ISIC_0001119.jpg*, enquanto o gaussiano venceu em todas as métricas em *ISIC_0011094.jpg*, e a diferença de SSIM no agregado das três imagens ficou na quarta casa decimal.

A mediana foi a menos indicada neste experimento, com o pior SSIM nas três imagens. Isso era esperado: ela é eficaz contra ruído impulsivo, do tipo sal e pimenta, porque elimina valores isolados extremos, mas o ruído gaussiano é distribuído de forma contínua em torno da intensidade original, e nesse caso substituir o pixel pela mediana da vizinhança descarta informação de textura sem ganho correspondente.

Diante do empate técnico entre média e gaussiano, foi escolhido o **filtro gaussiano** pela coerência entre o filtro e o modelo de degradação: como o ruído inserido tem distribuição gaussiana, o filtro gaussiano é o que melhor corresponde ao processo que se deseja reverter.

2.6 Aguçamento: high-boost

Para o realce foram implementadas duas técnicas: o **laplaciano** e o **high-boost**.

No laplaciano a imagem realçada é obtida por $g(x, y) = f(x, y) - c \cdot \nabla^2 f(x, y)$, em que $\nabla^2 f(x, y)$ é a resposta da máscara laplaciana. Foi usada a máscara de quatro vizinhos e $c = 0,28$. O valor de c foi reduzido bem abaixo de 1 de propósito: como a imagem já passou pela

equalização, que amplia as diferenças de intensidade, um c próximo de 1 saturava regiões inteiras e destacava os artefatos de lente e os pelos com a mesma intensidade das bordas da lesão.

No high-boost a imagem é somada a uma máscara de detalhes obtida pela diferença entre a imagem e sua versão borrada, ou seja, $g(x, y) = f(x, y) + k \cdot (f(x, y) - f_{\text{borrada}}(x, y))$. Foram usados $k = 1,0$, máscara gaussiana 3×3 e $\sigma = 1,0$ para gerar a versão borrada.

O high-boost foi superior ao laplaciano em todas as métricas e nas três imagens. A diferença tem uma explicação direta: o laplaciano é uma segunda derivada e responde fortemente a variações de um pixel para outro, exatamente o comportamento do ruído residual que sobrou depois da suavização. O high-boost extrai os detalhes por diferença com uma versão suavizada, o que já filtra parte dessas variações de altíssima frequência antes de reforçá-las.

Outro ponto que pesou na escolha é o requisito do enunciado de que o resultado final não seja apenas uma imagem de bordas isoladas. O high-boost atende a isso por construção, porque parte da imagem completa e apenas soma os detalhes sobre ela.

2.7 Configurações do pipeline

O enunciado pede pelo menos duas configurações. Foram testadas três, todas com os mesmos parâmetros e mudando apenas a ordem das etapas:

- **Configuração 1 (pipeline original):** ruído $\rightarrow$ equalização de histograma $\rightarrow$ filtro gaussiano $\rightarrow$ high-boost.
- **Configuração 2:** ruído $\rightarrow$ filtro gaussiano $\rightarrow$ equalização de histograma $\rightarrow$ high-boost. A suavização passa a vir antes da operação pontual, de modo que a equalização atue sobre uma imagem já limpa e não amplifique o ruído.
- **Configuração 3 (referência de controle):** equalização de histograma $\rightarrow$ ruído $\rightarrow$ filtro gaussiano $\rightarrow$ high-boost. Aqui a operação pontual é aplicada antes da degradação.

A Configuração 3 merece um comentário. Ela não é aplicável na prática, porque exige conhecer a imagem limpa antes de ela ser degradada, e no mundo real o ruído já vem junto com a captura. Ela foi mantida como controle experimental: serve para medir quanto da perda de qualidade das outras duas configurações vem do próprio ruído e quanto vem da interação entre o ruído e a equalização. Como a equalização é uma transformação não linear que expande faixas de intensidade pouco povoadas, ela também amplia a amplitude do ruído presente nessas faixas, e a Configuração 3 isola exatamente esse efeito.

2.8 Métricas escolhidas

Foram selecionadas as métricas **PSNR** e **SSIM**.

O **PSNR** avalia a fidelidade global da imagem em relação à referência, derivando do erro quadrático médio e expressando o resultado em decibéis. Ele responde bem à pergunta de quanto a imagem processada se afastou, em intensidade, da imagem que se desejava obter.

O **SSIM** compara luminância, contraste e estrutura em janelas locais e, por isso, mede algo que o PSNR não captura: se os contornos e a textura da lesão foram preservados. Como o objetivo do pipeline é reduzir ruído e realçar estruturas sem apagar detalhes nem criar artefatos, era necessário ter uma métrica sensível à estrutura ao lado de uma métrica de fidelidade.

As métricas MSE e RMSE foram calculadas durante os testes, mas não foram escolhidas como métricas principais porque medem essencialmente o mesmo aspecto que o PSNR, que é o erro médio entre as intensidades dos pixels. Elas são úteis para quantificar diferenças numéricas, mas não avaliam a preservação das estruturas, dos contornos e do contraste local da lesão. Seus valores foram mantidos nas tabelas de comparação entre filtros por serem úteis para a escolha interna de cada etapa.

Um detalhe importante da metodologia: a imagem de **referência** não é a imagem original em tons de cinza, e sim a imagem original submetida ao mesmo pipeline, sem a etapa de ruído. Comparar a saída do pipeline com a imagem original penalizaria o processamento pelas mudanças que ele deve produzir, como o aumento de contraste da equalização. Usando como referência a imagem limpa processada pelo mesmo caminho, as métricas medem apenas o quanto o ruído conseguiu desviar o resultado.

3. IMPLEMENTAÇÃO

O código foi escrito em Python no Google Colab, organizado em células que seguem a mesma ordem das etapas do enunciado. As funções auxiliares ficam em uma célula inicial e as etapas seguintes reutilizam essas funções, por isso as células devem ser executadas na sequência. As bibliotecas usadas são *numpy* para a representação matricial das imagens, *opencv* apenas para leitura e exibição, *matplotlib* para os gráficos de histograma e *scikit-image* para a geração do ruído e para o cálculo das métricas.

Esta seção reúne os trechos mais relevantes da implementação. O código completo está no notebook entregue junto com o relatório.

3.1 Conversão para tons de cinza e histograma

A conversão para tons de cinza usa os pesos de luminância aplicados diretamente sobre os canais BGR retornados pelo OpenCV. O histograma é construído percorrendo a imagem pixel a pixel e acumulando a contagem por nível de intensidade; quando normalizado, cada posição passa a representar a probabilidade daquele nível.

```
def imagem_colorida_para_cinza(img):
    if img is None:
        raise ValueError("img deve ser uma imagem colorida.")

    return np.array((0.114 * img[:, :, 0] + 0.587 * img[:, :, 1] + 0.299 * img[:, :, 2]),
dtype=np.uint8)

def calcular_histograma(img_cinza, normalizado=False):
    if img_cinza.ndim != 2:
        raise ValueError("A imagem deve estar em escala de cinza.")

    histograma = np.zeros(256)
    altura, largura = img_cinza.shape

    for i in range(altura):
        for j in range(largura):
            histograma[img_cinza[i,j]] += 1

    if normalizado:
        return histograma / img_cinza.size
    else:
        return histograma
```

Código 1 – Conversão para tons de cinza e cálculo do histograma.

3.2 Equalização de histograma

A equalização calcula o histograma normalizado, acumula-o para obter a função de distribuição acumulada e usa essa curva como tabela de mapeamento de intensidades. Cada nível de cinza original é substituído pelo valor da acumulada naquele ponto multiplicado por 255. O arredondamento é feito somando 0,5 e truncando, e o resultado é limitado à faixa de 0 a 255.

```
def equalizar_histograma(img_cinza):
    if img_cinza.ndim != 2:
```

```

        raise ValueError("A imagem deve estar em escala de cinza.")

    histograma = calcular_histograma(img_cinza, normalizado=True)

    altura, largura = img_cinza.shape
    acumulado = np.zeros(256)
    soma = 0.0

    for intensidade in range(256):
        soma += histograma[intensidade]
        acumulado[intensidade] = soma

    mapeamento = np.zeros(256, dtype=np.uint8)

    for intensidade in range(256):
        nova_intensidade = 255 * acumulado[intensidade]
        nova_intensidade = int(nova_intensidade + 0.5)

        if nova_intensidade < 0:
            nova_intensidade = 0
        elif nova_intensidade > 255:
            nova_intensidade = 255

        mapeamento[intensidade] = nova_intensidade

    resultado = np.zeros((altura, largura), dtype=np.uint8)

    for i in range(altura):
        for j in range(largura):
            intensidade_original = img_cinza[i, j]
            resultado[i, j] = mapeamento[intensidade_original]

    return resultado

```

Código 2 – Equalização de histograma.

O uso da tabela de mapeamento é o que torna a função viável: a transformação é calculada uma única vez para os 256 níveis possíveis e depois apenas consultada para cada pixel, em vez de ser recalculada milhões de vezes.

3.3 Convolução e tratamento de bordas

Todos os filtros lineares do trabalho passam pela mesma rotina de convolução. Antes de percorrer a imagem, as bordas são estendidas por replicação, ou seja, os pixels fora do domínio

recebem o valor do pixel válido mais próximo. Essa escolha evita o escurecimento artificial das bordas que aconteceria com preenchimento por zeros, o que seria especialmente ruim aqui porque as imagens do ISIC têm a borda circular escura da lente.

```
def estender_bordas_replicando(img_cinza, borda):
    altura, largura = img_cinza.shape

    altura_estendida = altura + 2 * borda
    largura_estendida = largura + 2 * borda

    img_estendida = np.zeros((altura_estendida, largura_estendida), dtype=np.float64)

    for y in range(altura_estendida):
        for x in range(largura_estendida):

            y_original = y - borda
            x_original = x - borda

            if y_original < 0:
                y_original = 0
            elif y_original >= altura:
                y_original = altura - 1

            if x_original < 0:
                x_original = 0
            elif x_original >= largura:
                x_original = largura - 1

            img_estendida[y, x] = img_cinza[y_original, x_original]

    return img_estendida

def calcular_convolucao(img_cinza, mascara):
    if img_cinza.ndim != 2:
        raise ValueError("A imagem deve estar em escala de cinza.")

    if mascara.shape[0] != mascara.shape[1] or mascara.shape[0] % 2 == 0:
        raise ValueError("A máscara deve ser quadrada e de dimensão ímpar.")

    altura, largura = img_cinza.shape
    tamanho = mascara.shape[0]
    borda = tamanho // 2
```

```

img_estendida = estender_bordas_replicando(img_cinza, borda)
resultado = np.zeros((altura, largura), dtype=np.float64)

for y in range(altura):
    for x in range(largura):
        soma = 0.0

        for i in range(tamanho):
            for j in range(tamanho):
                pixel = img_estendida[y + i, x + j]
                peso = mascara[i, j]

                soma += pixel * peso

        resultado[y, x] = soma

return resultado

```

Código 3 – Extensão de bordas por replicação e convolução genérica.

A função *calcular_convolucao* devolve o resultado em ponto flutuante, sem truncar. Isso é necessário porque o laplaciano e a máscara de detalhes do high-boost produzem valores negativos que ainda serão usados em uma soma posterior; truncar nesse momento destruiria a informação. A conversão para 8 bits só acontece no final, pela função *arredondar_e_limitar*.

3.4 Máscaras de suavização e filtro da mediana

A máscara gaussiana é gerada pela própria função exponencial e depois normalizada pela soma dos pesos, garantindo que o filtro preserve o brilho médio da imagem. A máscara da média é o caso particular em que todos os pesos são iguais a $\frac{1}{n^2}$.

```

def criar_mascara_gaussiana(tamanho=3, sigma=1.0):
    if tamanho < 3 or tamanho % 2 == 0:
        raise ValueError("O tamanho da máscara deve ser ímpar e maior ou igual a 3.")

    if sigma <= 0:
        raise ValueError("O valor de sigma deve ser maior que zero.")

    borda = tamanho // 2
    mascara = np.zeros((tamanho, tamanho), dtype=np.float64)
    soma_pesos = 0.0

    for y in range(-borda, borda + 1):

```

```

    for x in range(-borda, borda + 1):
        expoente = -(x ** 2 + y ** 2) / (2 * sigma ** 2)
        valor = math.exp(expoente)

        mascara[y + borda, x + borda] = valor
        soma_pesos += valor

for y in range(tamanho):
    for x in range(tamanho):
        mascara[y, x] = mascara[y, x] / soma_pesos

return mascara

```

Código 4 – Geração da máscara gaussiana normalizada.

O filtro da mediana não é uma convolução, porque a mediana não é uma operação linear. Ele percorre a vizinhança, monta a lista de valores, ordena e escolhe o elemento central. A ordenação também foi implementada manualmente, por inserção, para não depender de funções prontas.

```

def ordenar_lista_manual(valores):
    for i in range(1, len(valores)):
        atual = valores[i]
        j = i - 1

        while j >= 0 and valores[j] > atual:
            valores[j + 1] = valores[j]
            j -= 1

        valores[j + 1] = atual

    return valores

def filtro_mediana(img_cinza, tamanho=3):
    altura, largura = img_cinza.shape
    borda = tamanho // 2

    img_estendida = estender_bordas_replicando(img_cinza, borda)
    resultado = np.zeros((altura, largura), dtype=np.uint8)

    for y in range(altura):
        for x in range(largura):
            valores = []

            for i in range(tamanho):

```

```

        for j in range(tamanho):
            valores.append(img_estendida[y + i, x + j])

    valores_ordenados = ordenar_lista_manual(valores)

    indice_mediana = len(valores_ordenados) // 2
    resultado[y, x] = valores_ordenados[indice_mediana]

return resultado

```

Código 5 – Filtro da mediana com ordenação por inserção.

3.5 Aguçamento: laplaciano e high-boost

As duas técnicas de realce reaproveitam a mesma rotina de convolução. O laplaciano subtrai da imagem a resposta da máscara multiplicada por um fator c ; o high-boost soma à imagem a diferença entre ela e sua versão borrada, multiplicada por k .

```

def filtro_laplaciano(img_cinza, c=1.0, diagonais=False):
    laplaciano = calcular_convolucao(img_cinza, criar_mascara_laplaciana(diagonais))

    altura, largura = img_cinza.shape
    resultado = np.zeros((altura, largura), dtype=np.float64)

    #  $g(x, y) = f(x, y) - c * \nabla^2 f(x, y)$ 
    for y in range(altura):
        for x in range(largura):
            resultado[y, x] = img_cinza[y, x] - c * laplaciano[y, x]

    return converter_para_uint8(resultado)

def filtro_high_boost(img_cinza, k=1.5, tamanho=3, sigma=1.0):
    if k < 1:
        raise ValueError("O valor de k deve ser maior ou igual a 1.")

    img_borrada = calcular_convolucao(img_cinza, criar_mascara_gaussiana(tamanho, sigma))

    altura, largura = img_cinza.shape
    resultado = np.zeros((altura, largura), dtype=np.float64)

    # High-Boost:  $f(x, y) + k * (f(x, y) - f_{borrada}(x, y))$ 
    for y in range(altura):
        for x in range(largura):
            mascara_detalhes = img_cinza[y, x] - img_borrada[y, x]

```

```

        resultado[y, x] = (img_cinza[y, x] + k * mascara_detalhes)

    return converter_para_uint8(resultado)

```

Código 6 – Filtros de aguçamento laplaciano e high-boost.

3.6 Avaliação por métricas

A função de avaliação recebe a imagem de referência e o resultado e devolve MSE, RMSE, PSNR e SSIM. O parâmetro `data_range=255` informa a faixa dinâmica das imagens de 8 bits, e `channel_axis=None` indica que as imagens são de canal único.

```

def metricas_performance(reference, result):
    if reference is None or result is None:
        raise ValueError("Os parâmetros devem estar preenchidos.")

    mse_val = mean_squared_error(reference, result)

    rmse_val = np.sqrt(mse_val)

    psnr_val = peak_signal_noise_ratio(reference, result, data_range=255)

    ssim_val = structural_similarity(reference, result, data_range=255, channel_axis=None)

    return {"mse": mse_val, "rmse": rmse_val, "psnr": psnr_val, "ssim": ssim_val}

```

Código 7 – Cálculo das métricas de desempenho.

3.7 Montagem das configurações do pipeline

Cada configuração é executada em um laço que processa duas versões da mesma imagem: a **referência**, que percorre o pipeline sem a etapa de ruído, e o **resultado**, que percorre o pipeline completo. As duas são comparadas ao final. O trecho abaixo mostra a Configuração 1; as demais mudam apenas a ordem das chamadas.

```

for index, nome_imagem in enumerate(imgs_originais):
    img = cv2.imread(ARQUIVOS_DATASET + nome_imagem)
    img_cinza = imagem_colorida_para_cinza(img)

    # Imagem Referência

    ref_etapa02 = equalizar_histograma(img_cinza)
    ref_etapa03 = filtro_gaussiano(ref_etapa02, TAMANHO_MASCARA_SUAVIZACAO, SIGMA_SUAVIZACAO)
    ref_etapa04 = filtro_high_boost(ref_etapa03, K_HIGH_BOOST, TAMANHO_MASCARA_AGUCAMENTO,
    SIGMA_AGUCAMENTO)

```

```

referencia_final_original = ref_etapa04

# Imagem Resultado

img_etapa01 = adicionar_ruido(img_cinza, 'gaussian', VARIANCIA)
img_etapa02 = equalizar_histograma(img_etapa01)
img_etapa03 = filtro_gaussiano(img_etapa02, TAMANHO_MASCARA_SUAVIZACAO, SIGMA_SUAVIZACAO)
img_etapa04 = filtro_high_boost(img_etapa03, K_HIGH_BOOST, TAMANHO_MASCARA_AGUCAMENTO,
SIGMA_AGUCAMENTO)

imgs_resultado_original[nome_imagem] = img_etapa04

```

Código 8 – Execução da Configuração 1 sobre as três imagens.

Os parâmetros usados em todas as configurações foram $VARIANCIA = 0.003$, $TAMANHO_MASCARA = 3$, $SIGMA = 1.0$ e $K_HIGH_BOOST = 1.0$.

4. RESULTADOS OBTIDOS

Esta seção apresenta os resultados de cada etapa, na ordem em que foram executados. Todas as métricas foram calculadas com a imagem de referência descrita na Seção 2.8.

4.1 Imagens originais



Figura 1 – Imagem 1 – ISIC_0010925.jpg (original).



Figura 2 – Imagem 2 – ISIC_0011094.jpg (original).




Figura 3 – Imagem 3 – ISIC_0001119.jpg (original).

As três imagens confirmam a caracterização feita na Seção 2.2. Em *ISIC_0010925.jpg* percebe-se a lesão escura e bem delimitada, além das linhas horizontais da lente na lateral direita. Em *ISIC_0011094.jpg* a lesão se confunde com a pele ao redor. Em *ISIC_0001119.jpg* os pelos cobrem boa parte da região de interesse e o carimbo de data aparece no canto inferior direito.

4.2 Conversão para tons de cinza e inserção de ruído

Sem ruído



Com ruído gaussiano (var = 0,003)





Figura 4 – Imagem 1 – ISIC_0010925.jpg: versão em tons de cinza antes e depois da inserção do ruído.

Sem ruído



Com ruído gaussiano (var = 0,003)





Figura 5 – Imagem 2 – ISIC_0011094.jpg: versão em tons de cinza antes e depois da inserção do ruído.

Sem ruído



Com ruído gaussiano (var = 0,003)




Figura 6 – Imagem 3 – ISIC_0001119.jpg: versão em tons de cinza antes e depois da inserção do ruído.

O ruído é perceptível como uma granulação uniforme sobre toda a imagem, sem apagar as estruturas principais. É exatamente o comportamento pretendido: uma degradação forte o suficiente para exigir tratamento, mas que ainda permite avaliar o que cada filtro preserva.

4.3 Histogramas das imagens degradadas




Figura 7 – Imagem 1 – ISIC_0010925.jpg: imagem degradada e seu histograma normalizado.




Figura 8 – Imagem 2 – ISIC_0011094.jpg: imagem degradada e seu histograma normalizado.





Figura 9 – Imagem 3 – ISIC_0001119.jpg: imagem degradada e seu histograma normalizado.

Os três histogramas ocupam apenas parte da faixa de 0 a 255. *ISIC_0011094.jpg* é o caso mais evidente, com quase toda a massa concentrada em tons claros, o que explica o baixo contraste observado visualmente. Essa é a constatação que motivou a escolha da equalização de histograma como operação pontual.

4.4 Operação pontual: equalização de histograma e correção gama

Equalização de histograma



Correção gama ($\gamma = 1,3$)





Figura 10 – Imagem 1 – ISIC_0010925.jpg: comparação entre as duas transformações de intensidade testadas.

Equalização de histograma



Correção gama ($\gamma = 1,3$)





Figura 11 – Imagem 2 – ISIC_0011094.jpg: comparação entre as duas transformações de intensidade testadas.

Equalização de histograma



Correção gama ($\gamma = 1,3$)




Figura 12 – Imagem 3 – ISIC_0001119.jpg: comparação entre as duas transformações de intensidade testadas.

A diferença entre as duas técnicas fica clara nos histogramas. Com a correção gama o formato da distribuição é preservado e apenas deslocado, enquanto a equalização espalha as ocupações por toda a faixa disponível. Visualmente, a equalização produziu maior separação entre lesão e pele nas três imagens.

Em *ISIC_0011094.jpg*, onde a lesão é pouco definida, a equalização tornou as variações de intensidade bem mais perceptíveis. Em *ISIC_0010925.jpg* houve melhor evidência dos detalhes internos e das bordas da lesão. Já em *ISIC_0001119.jpg* a técnica aumentou a distinção entre lesão e fundo, mas também realçou os pelos e a textura da pele, o que é o primeiro sinal do problema discutido na Seção 5.3.




Figura 13 – Imagem 1 – ISIC_0010925.jpg após a equalização de histograma.




Figura 14 – Imagem 2 – ISIC_0011094.jpg após a equalização de histograma.




Figura 15 – Imagem 3 – ISIC_0001119.jpg após a equalização de histograma.

4.5 Suavização




Figura 16 – Imagem 1 – ISIC_0010925.jpg: da esquerda para a direita, imagem equalizada, filtro da média, filtro gaussiano e filtro da mediana (janela 3x3).




Figura 17 – Imagem 2 – ISIC_0011094.jpg: da esquerda para a direita, imagem equalizada, filtro da média, filtro gaussiano e filtro da mediana (janela 3x3).



Figura 18 – Imagem 3 – ISIC_0001119.jpg: da esquerda para a direita, imagem equalizada, filtro da média, filtro gaussiano e filtro da mediana (janela 3x3).

Tabela 1 – Desempenho dos filtros de suavização em cada imagem (janela 3x3, $\sigma = 1,0$).

Imagem	Filtro	MSE	RMSE	PSNR (dB)	SSIM
ISIC_0010925	Média	248,5175	15,7644	24,1772	0,5782
ISIC_0010925	Gaussiano	256,2415	16,0075	24,0443	0,5664
ISIC_0010925	Mediana	251,9904	15,8742	24,1170	0,5005
ISIC_0011094	Média	658,2571	25,6565	19,9468	0,4937
ISIC_0011094	Gaussiano	649,7610	25,4904	20,0033	0,5137

ISIC_0011094	Mediana	686,5814	26,2027	19,7639	0,4529
ISIC_0001119	Média	585,6301	24,1998	20,4546	0,4071
ISIC_0001119	Gaussiano	606,7518	24,6323	20,3007	0,3981
ISIC_0001119	Mediana	594,2213	24,3767	20,3913	0,3417

Tabela 2 – Média das métricas de suavização sobre as três imagens.

Métrica (média das 3 imagens)	Média	Gaussiano	Mediana
MSE	497,4682	504,2514	510,9310
RMSE	21,8736	22,0434	22,1512
PSNR (dB)	21,5262	21,4494	21,4241
SSIM	0,4930	0,4927	0,4317

No agregado, média e gaussiano ficam praticamente empatados: a diferença de SSIM aparece só na terceira casa decimal e a de PSNR é de 0,07 dB. A mediana é claramente a pior em SSIM, com 0,4317 contra aproximadamente 0,49 das outras duas, confirmando que ela não é adequada para ruído gaussiano. O filtro gaussiano foi o escolhido, como justificado na Seção 2.5.




Figura 19 – Imagem 1 – ISIC_0010925.jpg após a suavização com filtro gaussiano.




Figura 20 – Imagem 2 – ISIC_0011094.jpg após a suavização com filtro gaussiano.




Figura 21 – Imagem 3 – ISIC_0001119.jpg após a suavização com filtro gaussiano.

4.6 Aguçamento




Figura 22 – Imagem 1 – ISIC_0010925.jpg: da esquerda para a direita, imagem suavizada, laplaciano ($c = 0,28$) e high-boost ($k = 1,0$).




Figura 23 – Imagem 2 – ISIC_0011094.jpg: da esquerda para a direita, imagem suavizada, laplaciano ($c = 0,28$) e high-boost ($k = 1,0$).




Figura 24 – Imagem 3 – ISIC_0001119.jpg: da esquerda para a direita, imagem suavizada, laplaciano ($c = 0,28$) e high-boost ($k = 1,0$).

Tabela 3 – Desempenho das técnicas de aguçamento em cada imagem.

Imagem	Técnica	MSE	RMSE	PSNR (dB)	SSIM
ISIC_0010925	Laplaciano	327,2275	18,0894	22,9823	0,4577
ISIC_0010925	High-boost	315,7409	17,7691	23,1375	0,4710
ISIC_0011094	Laplaciano	678,8342	26,0544	19,8132	0,4623
ISIC_0011094	High-boost	651,0759	25,5162	19,9945	0,4753
ISIC_0001119	Laplaciano	785,1193	28,0200	19,1814	0,2948
ISIC_0001119	High-boost	756,5850	27,5061	19,3422	0,3053

O high-boost venceu em todas as métricas e em todas as imagens, com ganho em PSNR e em SSIM sobre o laplaciano. Comparando com a Tabela 1, nota-se que o PSNR cai em relação à etapa de suavização nas três imagens. Isso é esperado e não indica falha: o aguçamento amplifica

diferenças, e parte dessas diferenças é ruído residual. O que interessa é que o ganho de nitidez venha acompanhado do menor prejuízo possível, e é justamente nesse ponto que o high-boost se sai melhor.




Figura 25 – Imagem 1 – ISIC_0010925.jpg após o aguçamento com high-boost.




Figura 26 – Imagem 2 – ISIC_0011094.jpg após o aguçamento com high-boost.





Figura 27 – Imagem 3 – ISIC_0001119.jpg após o aguçamento com high-boost.

4.7 Configurações completas do pipeline

Configuração 1 – ruído → equalização → gaussiano → high-boost

Imagem degradada



Resultado do pipeline





Figura 28 – Imagem 1 – ISIC_0010925.jpg na Configuração 1: imagem degradada e resultado final, com seus histogramas.

Imagem degradada



Resultado do pipeline





Figura 29 – Imagem 2 – ISIC_0011094.jpg na Configuração 1: imagem degradada e resultado final, com seus histogramas.

Imagem degradada



Resultado do pipeline




Figura 30 – Imagem 3 – ISIC_0001119.jpg na Configuração 1: imagem degradada e resultado final, com seus histogramas.

Tabela 4 – Métricas da Configuração 1 em relação à imagem de referência.

Imagem	PSNR degradada	SSIM degradada	PSNR resultado	SSIM resultado
ISIC_0010925	16,4724 dB	0,2820	23,1178 dB	0,4765
ISIC_0011094	10,9817 dB	0,2845	19,9007 dB	0,4944
ISIC_0001119	13,3264 dB	0,2432	19,3059 dB	0,3153

Configuração 2 – ruído → gaussiano → equalização → high-boost




Figura 31 – Imagem 1 – ISIC_0010925.jpg: resultado da Configuração 2 e seu histograma.




Figura 32 – Imagem 2 – ISIC_0011094.jpg: resultado da Configuração 2 e seu histograma.




Figura 33 – Imagem 3 – ISIC_0001119.jpg: resultado da Configuração 2 e seu histograma.

Tabela 5 – Métricas da Configuração 2 em relação à imagem de referência.

Imagem	PSNR degradada	SSIM degradada	PSNR resultado	SSIM resultado
--------	----------------	----------------	----------------	----------------

ISIC_0010925	16,4262 dB	0,2789	22,9185 dB	0,4509
ISIC_0011094	10,8102 dB	0,2750	19,6792 dB	0,4958
ISIC_0001119	13.2502 dB	0,2380	19.2609 dB	0,3077

Configuração 3 – equalização → ruído → gaussiano → high-boost




Figura 34 – Imagem 1 – ISIC_0010925.jpg: resultado da Configuração 3 e seu histograma.




Figura 35 – Imagem 2 – ISIC_0011094.jpg: resultado da Configuração 3 e seu histograma.




Figura 36 – Imagem 3 – ISIC_0001119.jpg: resultado da Configuração 3 e seu histograma.

Tabela 6 – Métricas da Configuração 3, usada como controle experimental.

Imagem	PSNR degradada	SSIM degradada	PSNR resultado	SSIM resultado
ISIC_0010925	25,3015 dB	0,4029	31,8667 dB	0,7466
ISIC_0011094	23.3973 dB	0,6181	31,8745 dB	0,8882
ISIC_0001119	25.1861 dB	0,4652	31,8869 dB	0,7802

Os números das três tabelas mostram que, em todos os casos, o pipeline melhorou de forma significativa as métricas em relação à imagem degradada. A comparação entre as configurações é feita na seção seguinte.

5. ANÁLISE E DISCUSSÃO

Esta seção compara as três configurações, identifica a melhor para cada imagem e discute os pontos em que alguma técnica se comportou de forma inadequada.

5.1 Comparação entre as configurações

Tabela 7 – Comparação das três configurações. Δ indica o ganho em relação à imagem degradada correspondente.

Imagem	Configuração	PSNR (dB)	Δ PSNR	SSIM	Δ SSIM
ISIC_0010925	Config. 1	23,1178	+6,65	0,4765	+0,195

<i>ISIC_0010925</i>	Config. 2	22,9185	+6,49	0,4509	+0,172
<i>ISIC_0010925</i>	Config. 3	31,8667	+6,57	0,7466	+0,344
<i>ISIC_0011094</i>	Config. 1	19,9007	+8,92	0,4944	+0,210
<i>ISIC_0011094</i>	Config. 2	19,6792	+8,87	0,4958	+0,221
<i>ISIC_0011094</i>	Config. 3	31,8745	+8,48	0,8882	+0,270
<i>ISIC_0001119</i>	Config. 1	19,3059	+5,98	0,3153	+0,072
<i>ISIC_0001119</i>	Config. 2	19,2609	+6,01	0,3077	+0,070
<i>ISIC_0001119</i>	Config. 3	31,8869	+6,70	0,7802	+0,315

Entre as duas configurações aplicáveis na prática, a **Configuração 1 venceu em cinco das seis comparações de resultado final**. A Configuração 2 ficou à frente apenas no SSIM de *ISIC_0011094.jpg*, com 0,4958 contra 0,4944. Além disso, na *ISIC_0001119.jpg*, a Configuração 2 apresentou Δ PSNR ligeiramente maior, de +6,01 dB contra +5,98 dB. As diferenças são pequenas e devem ser interpretadas com cautela, pois correspondem a uma única realização do ruído e as duas configurações utilizam referências processadas de acordo com suas respectivas ordens de operação.

O resultado contraria a intuição inicial do grupo. Esperava-se que suavizar antes de equalizar fosse melhor, porque a equalização não amplificaria o ruído residual. Entretanto, os resultados indicam que, ao suavizar antes, a equalização é calculada sobre um histograma já modificado pela filtragem. A curva de mapeamento resultante pode se afastar da curva obtida na imagem de referência e reduzir a preservação do contraste local, aspecto ao qual o SSIM é particularmente sensível.

A **Configuração 3** apresentou valores muito superiores, com PSNR próximo de 31,9 dB e SSIM entre 0,7466 e 0,8882 nas três imagens. Essa diferença não deve ser interpretada como uma

superioridade prática da configuração, pois nela o ruído é inserido somente após a equalização. Ela foi mantida como controle experimental para evidenciar o efeito de submeter uma imagem ruidosa a uma transformação não linear de intensidade.

Nas imagens degradadas, a Configuração 3 parte de PSNR entre 23,3973 e 25,3015 dB, enquanto as Configurações 1 e 2 partem de 10,8102 a 16,4724 dB, usando a mesma variância de ruído. O contraste entre esses resultados sugere que a presença do ruído antes da equalização aumenta substancialmente sua influência sobre a imagem. Como as referências diferem de acordo com cada configuração, essa comparação deve ser entendida como evidência do efeito da ordem das operações, e não como uma equivalência absoluta entre os valores de PSNR.

Esse é o principal resultado do experimento e justifica a manutenção de uma configuração que não seria adotada como pipeline final. Ela mostra que aplicar uma operação pontual não linear sobre uma imagem já degradada pode estar associado a uma diferença de aproximadamente 9 a 13 dB no PSNR da imagem degradada, neste conjunto de testes.

5.2 Melhor configuração por imagem

- **ISIC_0010925.jpg:** a Configuração 1 é a melhor entre as aplicáveis, vencendo tanto em PSNR, com 23,1178 dB contra 22,9185 dB, quanto em SSIM, com 0,4765 contra 0,4509. Esse resultado é coerente com o bom contraste original da lesão e com a presença de um artefato localizado, que interfere menos na estrutura principal da imagem.
- **ISIC_0011094.jpg:** as duas configurações praticamente empatam. A Configuração 1 apresenta PSNR ligeiramente maior, com 19,9007 dB contra 19,6792 dB, enquanto a Configuração 2 apresenta SSIM ligeiramente superior, com 0,4958 contra 0,4944. Como essa imagem contém uma lesão de baixo contraste e o SSIM avalia a preservação de luminância, contraste e estrutura local, a Configuração 2 é defensável para esse caso específico. Essa também foi a imagem com maior ganho de PSNR entre as configurações aplicáveis, chegando a +8,92 dB na Configuração 1.
- **ISIC_0001119.jpg:** a Configuração 1 vence no SSIM, com 0,3153 contra 0,3077, enquanto a Configuração 2 apresenta Δ PSNR marginalmente maior, com +6,01 dB contra +5,98 dB. O aspecto mais relevante, porém, é o baixo SSIM das duas configurações em comparação às demais imagens. Os pelos, as linhas da lente e o carimbo de data são realçados junto com a lesão, prejudicando a preservação estrutural medida pela métrica.

No conjunto, a **Configuração 1** é recomendada como pipeline padrão, pois apresentou o desempenho mais consistente nas três imagens e venceu cinco das seis comparações de PSNR e SSIM entre as configurações aplicáveis.

5.3 Comportamentos inadequados e limitações

Filtro da mediana sobre ruído gaussiano

A mediana foi a técnica com pior comportamento entre as testadas, apresentando SSIM médio de 0,4317, contra 0,4930 para o filtro da média e 0,4927 para o filtro gaussiano. Esse comportamento é esperado, pois a mediana é mais adequada ao ruído impulsivo, como o ruído sal e pimenta, no qual valores extremos e isolados podem ser removidos pela ordenação da vizinhança.

No ruído gaussiano, os pixels são perturbados de forma contínua em torno de sua intensidade original. Nesse cenário, substituir o pixel central pela mediana da vizinhança pode suavizar texturas e detalhes sem remover a perturbação de forma proporcional, o que prejudica a métrica estrutural.

Equalização de histograma aplicada sobre imagem ruidosa

A equalização de histograma pode amplificar o efeito visual do ruído quando é aplicada sobre uma imagem já degradada. Como a técnica expande faixas de intensidade pouco povoadas do histograma, pequenas diferenças entre níveis de cinza podem se tornar mais evidentes após o mapeamento.

Os resultados da Configuração 3 reforçam esse comportamento como controle experimental: quando o ruído não passa pela equalização, as métricas da imagem degradada permanecem substancialmente mais próximas da referência. Ainda assim, essa comparação deve ser analisada junto à limitação metodológica de que cada configuração possui uma referência própria.

Realce de artefatos junto com as estruturas de interesse

A equalização e o aguçamento não distinguem estruturas clinicamente relevantes de artefatos. Em *ISIC_0001119.jpg*, os fios de cabelo, as linhas diagonais da lente e o carimbo de data foram realçados juntamente com as bordas da lesão.

Esse é o principal motivo do SSIM baixo dessa imagem em todas as configurações aplicáveis. Embora o pipeline aumente a visibilidade global, ele também torna mais salientes elementos sem valor clínico, que podem dificultar uma etapa posterior de classificação. Para imagens desse tipo, seria indicada uma etapa prévia de remoção de pelos, fora do escopo deste trabalho.

Laplaciano e a escolha do fator c

O laplaciano exigiu ajuste fino do fator (c). Com valores próximos de 1, que correspondem a uma aplicação mais direta da técnica, o resultado saturava regiões da imagem e destacava o ruído residual quase tanto quanto as bordas da lesão.

O valor foi reduzido para $c = 0,28$, mas, mesmo assim, o laplaciano ficou abaixo do high-boost em todas as métricas e nas três imagens. A sensibilidade da segunda derivada a variações locais, útil para evidenciar bordas, torna-se uma limitação quando ainda há ruído remanescente após a suavização.

Queda do PSNR na etapa de aguçamento

Ao comparar o filtro gaussiano, escolhido para a etapa de suavização, com o resultado do high-boost, observa-se uma redução de PSNR após o aguçamento. Essa redução foi de aproximadamente 0,91 dB em *ISIC_0010925.jpg*, 0,01 dB em *ISIC_0011094.jpg* e 0,96 dB em *ISIC_0001119.jpg*.

Esse comportamento não indica necessariamente falha do pipeline. O aguçamento aumenta as diferenças locais de intensidade para tornar bordas e detalhes mais visíveis, e parte dessas diferenças também pode corresponder a ruído residual. PSNR e SSIM medem proximidade em relação à referência, mas não avaliam diretamente a legibilidade clínica ou a nitidez percebida. Por isso, a avaliação visual foi mantida ao lado das métricas em todas as etapas.

Limitações do experimento

- As Configurações 1 e 2 usam **referências diferentes**, cada uma processada pelo seu próprio pipeline sem ruído. Isso é coerente com a metodologia adotada, mas significa que a comparação direta dos valores absolutos de PSNR entre as duas deve ser lida com cuidado. Os valores de Δ , calculados dentro de cada configuração, são a comparação mais confiável.

- Todo o processamento foi feito em tons de cinza. A informação de cor é um dos critérios clínicos do melanoma e foi descartada logo no início do pipeline.
- A equalização usada é **global**. Uma variante adaptativa por blocos, como o CLAHE, provavelmente teria amplificado menos o ruído em regiões homogêneas, mas exigiria uma implementação consideravelmente maior.
- As funções foram escritas com laços explícitos em Python, sem vetorização, para deixar o algoritmo evidente. O custo é o tempo de execução: a convolução é $O(\text{altura} \cdot \text{largura} \cdot k^2)$ em laços interpretados, o que torna o processamento das três imagens lento no Colab.

5.4 Conclusão

O pipeline proposto melhorou de forma consistente as três imagens em relação às respectivas imagens degradadas, com ganhos entre aproximadamente 6 e 9 dB de PSNR e entre 0,07 e 0,22 de SSIM nas configurações aplicáveis. A combinação escolhida foi a equalização de histograma, o filtro gaussiano 3x3 com $\sigma = 1,0$ e o high-boost com $k = 1,0$ aplicada na ordem da Configuração 1.

Os testes por etapa mostraram que a escolha das técnicas deve considerar o tipo de degradação presente. A mediana apresentou pior resultado porque é mais apropriada para ruído impulsivo do que para ruído gaussiano. O laplaciano também apresentou desempenho inferior ao high-boost, pois sua sensibilidade a variações locais intensificou parte do ruído residual.

O experimento de controle evidenciou ainda a influência da ordem das operações. Os resultados sugerem que aplicar a equalização sobre uma imagem já ruidosa aumenta significativamente o afastamento em relação à referência. Nesse conjunto, a diferença observada no PSNR das imagens degradadas ficou aproximadamente entre 9 e 13 dB, devendo ser interpretada junto à limitação de que cada configuração utiliza sua própria referência.

Por fim, o comportamento de *ISIC_0001119.jpg* mostra o limite da abordagem adotada: técnicas globais de equalização e aguçamento não separam a lesão de artefatos presentes na imagem. Para casos com pelos, marcas de captura ou outros elementos indesejados, seria necessária uma etapa específica de pré-processamento antes da aplicação do pipeline.

6. REFERÊNCIAS BIBLIOGRÁFICAS

VIEL, Felipe. Projeto M1 – Operações Pontuais e Filtragem Espacial. Universidade do Vale do Itajaí, 2026.

FOI, A.; TRIMECHE, M.; KATKOVNIK, V.; EGIASARIAN, K. Practical Poissonian-Gaussian Noise Modeling and Fitting for Single-Image Raw-Data. **IEEE Transactions on Image Processing**, v. 17, n. 10, p. 1737-1754, out. 2008.

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. 4. ed. New York: Pearson, 2018.

INTERNATIONAL SKIN IMAGING COLLABORATION. **ISIC Archive**. Disponível em: <https://www.isic-archive.com>. Acesso em: set. 2026.

VAN DER WALT, S. et al. scikit-image: image processing in Python. **PeerJ**, v. 2, e453, 2014.

WANG, Z.; BOVIK, A. C.; SHEIKH, H. R.; SIMONCELLI, E. P. Image Quality Assessment: From Error Visibility to Structural Similarity. **IEEE Transactions on Image Processing**, v. 13, n. 4, p. 600-612, abr. 2004.